Guide du formateur

Analyse des données d'un mémoire avec R et RStudio – Atelier pratique de 45 minutes

Étudiantes sages-femmes et infirmières – Écoles nationales de formation sanitaire, Togo

Avertissement. Toutes les données sont **entièrement synthétiques (fictives)**, générées à des fins d'enseignement. Elles ne proviennent d'aucune patiente ni d'aucun établissement réel. Aucun résultat ne doit être cité comme une donnée réelle.

Contenu du guide

- **1.** Vue d'ensemble de l'atelier
- **2. Partie A** – Préparation de la séance (R, RStudio, projet, données)
- **3.** Scénario de la formation en direct (45 minutes)
- **4. Partie B** – Les concepts expliqués simplement
- **5. Partie C** – Démonstration des dix analyses (question, variables, méthode, code, résultat, interprétation, rédaction)
- **6. Partie D** – Difficultés fréquentes et solutions
- **7. Annexes** – Adapter le script à son propre mémoire ; rapport de vérification technique

1. Vue d'ensemble

Principe pédagogique. On ne présente pas un cours de programmation. On part d'une **question scientifique** posée dans un mémoire, on identifie les **variables** nécessaires, on choisit l'**analyse**, on exécute **quelques lignes de R**, on lit le **résultat**, on l'**interprète**, puis on apprend à le **rédiger**.

Élément	Contenu
Public	Étudiantes sages-femmes (Licence) et étudiants infirmiers préparant leur TFE ; connaissent Excel, Epi Info ou Stata ; aucune expérience du code.
Objectif	Reproduire de façon autonome les principales étapes d'une analyse de mémoire : importer, explorer, décrire, croiser, tester, représenter, exporter.
Données	400 femmes enceintes fictives, 22 variables (dictionnaire fourni). Valeurs manquantes volontairement présentes (IMC : 30 ; antécédent familial d'HTA : 12…).
Supports	Fiche participante (avant la séance), fiche corrigée (formateur), script `02_analyse_TFE.R`, dictionnaire, ce guide.
Durée et packages	45 minutes ; R de base + `ggplot2` uniquement.

À savoir avant de commencer. (1) La graine de simulation (135) a été retenue après essai de plusieurs graines pour obtenir un profil pédagogique équilibré : certaines associations sont significatives, d'autres non. Les effets programmés sont des choix de simulation, pas des faits. (2) Les scripts ont été exécutés avec succès sous R 4.3.3 (Linux). **Ils n'ont pas pu être testés sous Windows avec RStudio** dans l'environnement de conception : faites un essai complet la veille sur l'ordinateur de la séance. (3) Dans cette simulation, 5 des 6 tests de la section « facteurs associés » utilisent Fisher ou Welch ; le Chi-deux n'est applicable que pour la parité (Q8).

2. Partie A – Préparation de la séance

A1. Installer R

- Ouvrir `https://cran.r-project.org` → « Download R for Windows » → « base » → télécharger puis exécuter l'installateur (options par défaut). Une version récente (4.2 ou plus) est recommandée.
- Installer R **avant** RStudio.

A2. Installer RStudio

- Ouvrir `https://posit.co/download/rstudio-desktop/` → télécharger RStudio Desktop (gratuit) pour Windows → installer avec les options par défaut.

A3. Présenter l'interface

Volet	Rôle	Phrase à dire
Source (en haut à gauche)	Le script : la « recette » écrite	« Ici j'écris mes consignes. Rien ne se passe tant que je ne les exécute pas. »
Console (en bas à gauche)	Là où R répond	« Ici R affiche les résultats et les messages d'erreur. »
Environment (en haut à droite)	Les objets en mémoire (ex. donnees)	« Notre tableau de 400 femmes est ici. Cliquer dessus l'ouvre comme dans Excel. »
Files / Plots (en bas à droite)	Fichiers du projet ; graphiques créés	« Les graphiques apparaissent ici ; les fichiers aussi. »

A4. Ouvrir le projet

- **Décompresser l'archive ZIP** (clic droit → Extraire tout). Ne jamais travailler depuis l'intérieur du ZIP.
- Double-cliquer sur `Atelier_TFE.Rproj` (à la racine du dossier) : RStudio s'ouvre avec le bon dossier de travail. Le nom du projet s'affiche en haut à droite.
- Dans le volet Files, ouvrir `02_SCRIPTS_R` puis double-cliquer `02_analyse_TFE.R`.
- Si les accents s'affichent mal : menu File → Reopen with Encoding → UTF-8.

A5. Charger le dataset

Sélectionner les lignes de la Section 1 (jusqu'à `head(donnees)`) et appuyer sur Ctrl + Entrée, ou placer le curseur sur chaque ligne. Le script cherche seul le fichier CSV et crée les dossiers de résultats.

```
donnees <- read.csv2(file.path(dossier_projet, "01_DONNEES", "donnees_TFE_preeclampsie_Kara.csv"),
                     stringsAsFactors = FALSE, fileEncoding = "UTF-8")
head(donnees)
```

Liste de contrôle la veille : R et RStudio installés ; archive décompressée ; projet ouvert sans erreur ; **ggplot2 déjà installé** (exécuter la ligne 1.1 une fois avec Internet) ; `Ctrl + Maj + Entrée` exécute le script entier sans erreur ; une copie du dossier sur clé USB pour les participantes ; **plan B** : fiche corrigée et dossier `05_RESULTATS` déjà produits, à montrer si l'ordinateur tombe en panne.

3. Scénario de la formation en direct (45 minutes)

Étape	Activité	Durée	Repère horaire
1	Présentation du sujet et des questions scientifiques	5 min	0 – 5
2	Découverte du dataset dans RStudio	5 min	5 – 10
3	Statistiques descriptives (Q1 à Q3)	7 min	10 – 17
4	Tableaux et analyses croisées (Q4 à Q9)	8 min	17 – 25
5	Tests statistiques simples (Q5 à Q10)	8 min	25 – 33
6	Graphiques scientifiques avec ggplot2	8 min	33 – 41
7	Exportation et conclusion	4 min	41 – 45
Total		**45 min**	

Les dix questions sont toutes couvertes par les supports. Pour tenir le temps, on **détaille** une question par famille (Q1, Q5, Q10) et on **regroupe** les manipulations répétitives (Q6 à Q9 : même modèle de code, seuls les noms de variables changent).

Étape 1 – Présentation du sujet et des questions (5 min)

Objectif pédagogique	Montrer que chaque analyse répond à une question de mémoire.
Manipulation	Projeter la fiche participante ; lire le sujet et 3 ou 4 questions ; rappeler la démarche « question → variables → analyse → résultat → interprétation → rédaction ».
Résultat attendu	Aucun code. Les participantes repèrent les 10 questions et le tableau de correspondance.
Explication orale	« Vous avez déjà ces questions dans vos mémoires. Aujourd'hui on voit comment R y répond, sans refaire à la main ce que vous faites dans Excel. »
Question aux participantes	Quelle question de recherche de votre propre mémoire pourrait se traiter avec ce type de données ?

Étape 2 – Découverte du dataset (5 min)

Objectif pédagogique	Comprendre qu'une ligne = une femme et une colonne = une variable.
Manipulation	Exécuter la Section 1, puis explorer avec les cinq fonctions ci-dessous ; ouvrir `donnees` dans l'Environment.
Résultat attendu	`dim()` : 400 lignes et 22 colonnes ; `str()` : type de chaque variable ; `colSums(is.na())` : valeurs manquantes (imc : 30, atcd_familial_hta : 12).
Explication orale	« Une ligne, une femme. Une colonne, une variable. *int* et *num* sont des nombres, *chr* du texte. NA veut dire information manquante : R ne la remplace jamais par zéro. »
Question aux participantes	Combien y a-t-il de femmes ? Quelle variable a le plus de valeurs manquantes ?

Lignes de code à exécuter

```
head(donnees)
dim(donnees)
names(donnees)
str(donnees)
colSums(is.na(donnees))
```

Étape 3 – Statistiques descriptives (7 min)

Objectif pédagogique	Calculer moyenne, écart-type, médiane, effectifs et pourcentages.
Manipulation	Exécuter les blocs Q1, Q2 et Q3 ; commenter l'histogramme plus tard (étape 6).
Résultat attendu	L'âge moyen des 400 femmes enceintes incluses était de 26,4 ± 4,9 ans (médiane : 26 ans), avec des extrêmes de 17 et 45 ans. Tableau des niveaux d'instruction avec effectifs et pourcentages ; résumé de la gestité, de la parité, des CPN et de l'âge gestationnel.
Explication orale	« `$` signifie : la colonne age_ans du tableau donnees. `na.rm = TRUE` dit à R d'ignorer les cases manquantes. La moyenne résume, l'écart-type dit si les femmes se ressemblent. »
Question aux participantes	Pourquoi donner l'écart-type en plus de la moyenne ? Pourquoi les pourcentages du niveau d'instruction portent-ils sur 394 femmes et non 400 ?

Lignes de code à exécuter

```
age_moyenne    <- mean(donnees$age_ans, na.rm = TRUE)
age_ecart_type <- sd(donnees$age_ans, na.rm = TRUE)
age_mediane    <- median(donnees$age_ans, na.rm = TRUE)
effectifs_niveau <- table(donnees$niveau_instruction)
pourcentages_niveau <- round(100 * prop.table(effectifs_niveau), 1)
summary(variables_obst)
```

Étape 4 – Tableaux et analyses croisées (8 min)

Objectif pédagogique	Construire un tableau croisé avec les pourcentages calculés dans le bon sens.
Manipulation	Exécuter Q4, puis Q5 (tableau croisé et pourcentages en ligne) ; montrer en accéléré Q7, Q8, Q9 (même modèle).
Résultat attendu	Q4 : Parmi les 400 femmes enceintes incluses, 48 présentaient une prééclampsie, soit une proportion de 12,0 % dans l'échantillon (40 prééclampsies et 8 prééclampsies surajoutées à une HTA chronique). Tableau âge × prééclampsie avec pourcentages par tranche d'âge ; tableaux croisés pour l'HTA, la parité et le type de grossesse.
Explication orale	« `table(a, b)` croise deux variables. Le **`1`** dans `prop.table(tab, 1)` veut dire : pourcentages **dans chaque ligne**, c'est-à-dire parmi les femmes de chaque tranche d'âge. »
Question aux participantes	Pourquoi calcule-t-on le pourcentage de prééclampsie *à l'intérieur de chaque tranche d'âge* et pas sur les 400 femmes ?

Lignes de code à exécuter

```
tab_pe <- table(donnees$preeclampsie)
tab_q5 <- table(donnees$tranche_age, donnees$preeclampsie)
round(100 * prop.table(tab_q5, 1), 1)
tab_q7 <- table(donnees$atcd_hta_chronique, donnees$preeclampsie)
tab_q8 <- table(donnees$groupe_parite, donnees$preeclampsie)
tab_q9 <- table(donnees$type_grossesse, donnees$preeclampsie)
```

Étape 5 – Tests statistiques simples (8 min)

Objectif pédagogique	Choisir et lire un test ; interpréter une p-value avec prudence.
Manipulation	Pour Q5 : montrer les effectifs attendus, la règle Chi-deux/Fisher, puis la p-value. Montrer que Q6 à Q9 sont des copies du même bloc ; terminer par Q10 (test t).
Résultat attendu	Q5 : Test exact de Fisher : p = 0,165 ; Q6 : Test exact de Fisher : p = 0,009 ; Q7 : Test exact de Fisher : p = 0,003 ; Q8 : Test du Chi-deux de Pearson : p = 0,002 ; Q9 : Test exact de Fisher : p = 0,679 ; Q10 : Test t de Student (Welch) : p = 0,887.
Explication orale	« H0 dit : il n'y a pas de lien. La p-value mesure à quel point nos données seraient surprenantes si H0 était vraie. Petite p-value (< 0,05) : on rejette H0. Grande p-value : on ne peut pas conclure, **mais on n'a pas prouvé qu'il n'y a pas de lien**. »
Question aux participantes	Pour l'âge, p = 0,165 : peut-on dire que l'âge n'a aucun effet sur la prééclampsie ? (Non : absence de preuve n'est pas preuve d'absence.)

Lignes de code à exécuter

```
attendus_q5 <- outer(rowSums(tab_q5), colSums(tab_q5)) / sum(tab_q5)
round(attendus_q5, 1)
test_q5 <- fisher.test(tab_q5)
test_q8 <- chisq.test(tab_q8, correct = FALSE)
test_q10 <- t.test(age_ans ~ preeclampsie, data = donnees)
```

Étape 6 – Graphiques scientifiques avec ggplot2 (8 min)

Objectif pédagogique	Produire une figure propre, exportable dans Word.
Manipulation	Exécuter les graphiques 1, 3 et 4 ; modifier une couleur ou un titre en direct ; montrer le fichier PNG obtenu dans `05_RESULTATS/graphiques`.
Résultat attendu	Un histogramme de l'âge, un diagramme en barres de la prééclampsie par tranche d'âge, un boxplot de l'âge selon le statut ; 5 fichiers PNG à 300 dpi.
Explication orale	« ggplot se construit par couches avec le signe +. On donne les données, on choisit la forme (histogramme, barres), puis on ajoute titre, axes et couleurs. »
Question aux participantes	Que montre le graphique par tranche d'âge que le tableau montrait moins bien ?

Lignes de code à exécuter

```
g1 <- ggplot(donnees, aes(x = age_ans)) +
  geom_histogram(binwidth = 2, boundary = 14, fill = couleur_principale, color = "white") +
g1
ggsave(file.path(dossier_graphiques, "graphique1_distribution_age.png"),
       plot = g1, width = 16, height = 10, units = "cm", dpi = 300)
```

Étape 7 – Exportation et conclusion (4 min)

Objectif pédagogique	Obtenir des tableaux CSV réutilisables dans Word/Excel et reproduire l'analyse.
Manipulation	Exécuter la Section 7 ; ouvrir `Tableau4_facteurs_associes.csv` dans Excel ; conclure sur la réutilisation du script.
Résultat attendu	11 fichiers CSV dans `05_RESULTATS/tableaux` (tableaux 1 à 5, synthèses, tableaux de questions) et 5 PNG dans `05_RESULTATS/graphiques`.
Explication orale	« Si les données changent, vous relancez le script : tous les tableaux et graphiques se refont tout seuls. C'est la reproductibilité. Pour votre mémoire : changez le nom du fichier et des variables. »
Question aux participantes	Qu'auriez-vous à modifier pour utiliser ce script avec votre propre fichier de données ?

Lignes de code à exécuter

```
write.csv2(tableau4,           file.path(dossier_tableaux, "Tableau4_facteurs_associes.csv"),      row.names = FALSE, na =
```

4. Partie B – Les concepts expliqués simplement

Concept	Explication simple	Exemple obstétrical
Dataset (jeu de données)	Un tableau : une ligne par individu, une colonne par caractéristique.	Le fichier des 400 dossiers de femmes enceintes.
Observation	Une ligne du tableau : un individu étudié.	Une femme enceinte (F001).
Variable	Une colonne : une caractéristique mesurée ou notée.	L'âge, la parité, la pression artérielle.
Variable qualitative	Une catégorie, un état. On compte.	Oui/Non pour l'HTA chronique ; niveau d'instruction.
Variable quantitative	Un nombre avec lequel on peut calculer.	Âge en années ; IMC ; PAS en mmHg.
Moyenne	La somme des valeurs divisée par leur nombre.	Âge moyen : 26,4 ans.
Médiane	La valeur du milieu quand on range les valeurs : la moitié est en dessous, la moitié au-dessus.	Médiane de 26 ans : la moitié des femmes a 26 ans ou moins.
Écart-type	La dispersion typique autour de la moyenne. Petit : valeurs proches ; grand : valeurs étalées.	Âge : 26,4 ± 4,9 ans.
Fréquence (effectif)	Le nombre d'individus dans une catégorie.	48 femmes avec prééclampsie.
Pourcentage	L'effectif d'une catégorie divisé par le total de référence, × 100. Toujours préciser le total.	12,0 % = 48 / 400.
Tableau croisé	Un tableau qui croise deux variables qualitatives.	Tranche d'âge × prééclampsie.
Hypothèse nulle (H0)	L'hypothèse « il n'y a pas de différence / pas de lien », que l'on cherche à mettre en défaut.	H0 : la prééclampsie est aussi fréquente avec ou sans HTA chronique.
p-value	La probabilité d'observer des données aussi différentes de H0 (ou plus), si H0 était vraie. Ce n'est pas la probabilité que H0 soit vraie.	p = 0,009 : très peu probable de voir un tel écart par hasard si l'antécédent n'avait aucun lien.
Association statistique	Un lien observé entre deux variables. Elle n'indique pas la cause.	L'HTA chronique est associée à la prééclampsie ; cela ne dit pas qu'elle la cause dans ces données.

5. Partie C – Démonstration des dix analyses

Pour chaque question : (1) la question, (2) les variables, (3) la méthode, (4) le code R extrait tel quel du script, (5) le résultat, (6) l'interprétation, (7) la rédaction dans le mémoire.

Question 1 – Quel est l'âge moyen des femmes enceintes incluses dans l'étude ?

Variables	Âge maternel (`age_ans`)
Méthode	Statistiques descriptives d'une variable quantitative

Code R (extrait du script)

```
# QUESTION 1 : Quel est l'âge moyen des femmes enceintes incluses dans l'étude ?
age_moyenne    <- mean(donnees$age_ans, na.rm = TRUE)
age_ecart_type <- sd(donnees$age_ans, na.rm = TRUE)
age_mediane    <- median(donnees$age_ans, na.rm = TRUE)
age_min        <- min(donnees$age_ans, na.rm = TRUE)
age_max        <- max(donnees$age_ans, na.rm = TRUE)
cat("Âge moyen :", virgule(age_moyenne), "ans (écart-type :", virgule(age_ecart_type), ")\n")
cat("Médiane :", age_mediane, "ans ; minimum :", age_min, "; maximum :", age_max, "\n")

tableau_q1 <- data.frame(
  Statistique = c("Effectif valide", "Moyenne", "Ecart-type", "Médiane", "Minimum", "Maximum"),
  Valeur = c(sum(!is.na(donnees$age_ans)), round(age_moyenne, 1), round(age_ecart_type, 1),
             age_mediane, age_min, age_max))
tableau_q1
```

Que fait ce code ?

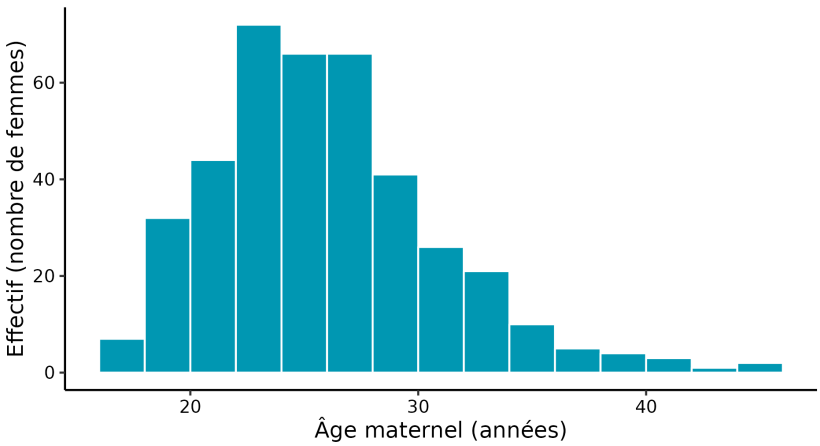
- `mean()` calcule la moyenne, `sd()` l'écart-type, `median()` la médiane.
- `na.rm = TRUE` : ignorer les valeurs manquantes.
- `cat()` affiche une phrase ; `virgule()` met la virgule décimale française.

Résultat

Statistique	Valeur
Effectif valide	400
Moyenne	26,4
Ecart-type	4,9
Médiane	26
Minimum	17
Maximum	45

Distribution de l'âge maternel

Femmes enceintes incluses (N = 400, données synthétiques)



Interprétation

L'âge moyen est de 26,4 ans, avec un écart-type de 4,9 ans : les âges s'écartent en moyenne de 4,9 ans autour de 26,4 ans. La moyenne est légèrement supérieure à la médiane (distribution un peu étalée vers les âges élevés). Les âges vont de 17 à 45 ans.

Comment l'écrire dans le mémoire

L'âge moyen des 400 femmes enceintes incluses était de 26,4 ± 4,9 ans (médiane : 26 ans), avec des extrêmes de 17 et 45 ans.

Question 2 – Quelles sont les principales caractéristiques sociodémographiques des participantes ?

Variables	Tranche d'âge, situation matrimoniale, niveau d'instruction, profession, milieu de résidence
Méthode	Effectifs et pourcentages (variables qualitatives) ; les pourcentages sont calculés sur les effectifs valides

Code R (extrait du script)

```
# QUESTION 2 : Quelles sont les principales caractéristiques sociodémographiques ?
# Un premier exemple pas à pas : le niveau d'instruction
effectifs_niveau <- table(donnees$niveau_instruction)
effectifs_niveau
pourcentages_niveau <- round(100 * prop.table(effectifs_niveau), 1)
pourcentages_niveau

# Le même travail pour toutes les variables du Tableau 1
tableau1 <- rbind(
  faire_tableau(donnees$tranche_age,             "Tranche d'âge"),
  faire_tableau(donnees$situation_matrimoniale,  "Situation matrimoniale"),
  faire_tableau(donnees$niveau_instruction,      "Niveau d'instruction"),
  faire_tableau(donnees$profession,              "Profession"),
  faire_tableau(donnees$milieu_residence,        "Milieu de résidence"))
tableau1
```

Que fait ce code ?

- `table()` compte les femmes par modalité.
- `prop.table()` transforme les effectifs en proportions ; × 100 et `round(…, 1)` donnent des pourcentages à une décimale.
- `faire_tableau()` répète ce travail pour chaque variable et ajoute la ligne « Données manquantes ».

Résultat

Variable	Modalité	Effectif	%
Tranche d'âge	Moins de 20 ans	21	5,2
	20-29 ans	289	72,2
	30-34 ans	65	16,2
	35 ans et plus	25	6,2
Situation matrimoniale	Célibataire	68	17,0
	Mariée	255	63,7
	Union libre	69	17,2
	Veuve/divorcée	8	2,0
Niveau d'instruction	Aucun	53	13,5
	Primaire	121	30,7
	Secondaire	177	44,9
	Supérieur	43	10,9
	Données manquantes	6	
Profession	Agricultrice	51	13,0
	Artisane	42	10,7
	Commerçante	125	31,9
	Élève/Étudiante	35	8,9
	Ménagère	122	31,1

Variable	Modalité	Effectif	%
	Salariée	17	4,3
	Données manquantes	8	
Milieu de résidence	Urbain	238	59,5
	Rural	162	40,5

Interprétation

La tranche d'âge la plus représentée est « 20-29 ans » (72,2 %). La situation matrimoniale la plus fréquente est « Mariée » (63,7 %) ; le niveau d'instruction le plus fréquent est « Secondaire » (44,9 % des 394 femmes renseignées). Pour la profession, 8 données sont manquantes : les pourcentages portent sur 392 femmes. Le milieu « Urbain » concerne 59,5 % des femmes.

Comment l'écrire dans le mémoire

La tranche d'âge de 20-29 ans était la plus représentée (72,2 %). Les femmes étaient majoritairement « mariée » (63,7 %). Le niveau d'instruction « secondaire » était le plus fréquent (44,9 %), et la profession la plus fréquente était « commerçante » (31,9 %). 59,5 % des femmes résidaient en milieu urbain.

Note pour le formateur : Toujours indiquer l'effectif valide quand il y a des données manquantes (ici niveau d'instruction : 6 manquantes ; profession : 8).

Question 3 – Quelles sont les caractéristiques obstétricales des participantes ?

Variables	Gestité, parité, nombre de consultations prénatales (CPN), âge gestationnel
Méthode	Statistiques descriptives (variables quantitatives) et tableaux de fréquences (variables regroupées en classes)

Code R (extrait du script)

```
# QUESTION 3 : Quelles sont les caractéristiques obstétricales des participantes ?
variables_obst <- donnees[, c("gestite", "parite", "nb_cpn", "age_gestationnel_sa")]
summary(variables_obst)

tableau2_quanti <- data.frame(
  Variable   = c("Gestité", "Parité", "Nombre de CPN", "Âge gestationnel (SA)"),
  N_valides  = colSums(!is.na(variables_obst)),
  Moyenne    = round(sapply(variables_obst, mean, na.rm = TRUE), 1),
  Ecart_type = round(sapply(variables_obst, sd, na.rm = TRUE), 1),
  Mediane    = sapply(variables_obst, median, na.rm = TRUE),
  Minimum    = sapply(variables_obst, min, na.rm = TRUE),
  Maximum    = sapply(variables_obst, max, na.rm = TRUE),
  row.names  = NULL)
tableau2_quanti

tableau2_categories <- rbind(
  faire_tableau(donnees$groupe_parite,   "Parité"),
  faire_tableau(donnees$groupe_cpn,      "Nombre de CPN"),
  faire_tableau(donnees$groupe_age_gest, "Âge gestationnel"))
tableau2_categories
```

Que fait ce code ?

- `summary()` donne minimum, quartiles, médiane, moyenne, maximum.
- `sapply(variables, mean)` applique la même fonction à plusieurs colonnes à la fois.
- `colSums(!is.na(…))` compte les valeurs renseignées.

Résultat

Variable	N valides	Moyenne	Écart-type	Médiane	Min	Max
Gestité	400	2,7	1,5	2	1	10
Parité	400	1,6	1,5	1	0	8

Variable	N valides	Moyenne	Écart-type	Médiane	Min	Max
Nombre de CPN	390	3,6	2,0	3	0	10
Âge gestationnel (SA)	400	34,4	4,3	35	21	41

Variable	Modalité	Effectif	%
Parité	Nullipare (0)	108	27,0
	1-2 accouchements	203	50,7
	3 accouchements et plus	89	22,2
Nombre de CPN	Moins de 4 CPN	203	52,1
	4 à 7 CPN	169	43,3
	8 CPN et plus	18	4,6
	Données manquantes	10	
Âge gestationnel	20-27 SA	27	6,8
	28-36 SA	226	56,5
	37 SA et plus	147	36,8

Interprétation

La parité moyenne est de 1,6 accouchement(s) antérieur(s) et 27,0 % des femmes sont nullipares. Le nombre moyen de CPN est de 3,6 (calculé sur 390 femmes) : 52,1 % ont fait moins de 4 CPN et seulement 4,6 % en ont fait 8 ou plus. L'âge gestationnel moyen est de 34,4 SA.

Comment l'écrire dans le mémoire

La gestité moyenne était de 2,7 ± 1,5 et la parité moyenne de 1,6 ± 1,5 ; 27,0 % des femmes étaient nullipares. Le nombre moyen de consultations prénatales était de 3,6 ± 2,0 (données disponibles pour 390 femmes), et 52,1 % des femmes avaient effectué moins de 4 CPN. L'âge gestationnel moyen était de 34,4 ± 4,3 SA.

Note pour le formateur : La parité est ici le nombre d'accouchements antérieurs ; la gestité compte aussi la grossesse actuelle et les pertes : on a toujours parité ≤ gestité − 1.

Question 4 – Quelle est la proportion de femmes présentant une prééclampsie dans l'échantillon étudié ?

Variables	Diagnostic de prééclampsie (`preeclampsie`, `type_diagnostic`)
Méthode	Effectif et pourcentage de cas

Code R (extrait du script)

```
# QUESTION 4 : Quelle est la proportion de femmes présentant une prééclampsie ?
tab_pe <- table(donnees$preeclampsie)
tab_pe
pct_pe <- 100 * tab_pe["Oui"] / sum(tab_pe)
cat("Prééclampsie :", tab_pe["Oui"], "cas sur", sum(tab_pe), "femmes, soit", virgule(pct_pe), "%\n")
# ATTENTION : ce pourcentage concerne l'échantillon, pas toute la population de Kara.

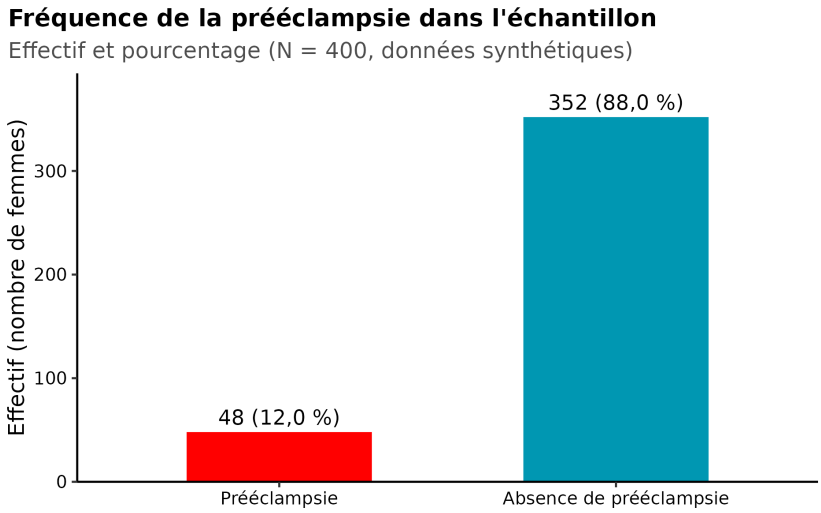
tableau3 <- rbind(
  faire_tableau(donnees$preeclampsie,    "Prééclampsie (toutes formes)"),
  faire_tableau(donnees$type_diagnostic, "Type de diagnostic"))
tableau3
```

Que fait ce code ?

- `tab_pe["Oui"]` lit l'effectif des cas dans le tableau.
- Le pourcentage se calcule sur l'ensemble de l'échantillon.

Résultat

Variable	Modalité	Effectif	%
Prééclampsie (toutes formes)	Non	352	88,0
	Oui	48	12,0
Type de diagnostic	Normotendue	327	81,8
	HTA gestationnelle	10	2,5
	HTA chronique seule	15	3,8
	Prééclampsie	40	10,0
	Prééclampsie surajoutée	8	2,0



Interprétation

48 femmes sur 400 présentent une prééclampsie, soit 12,0 % de l'échantillon (352 n'en présentent pas). Parmi les cas, 40 sont des prééclampsies et 8 des prééclampsies surajoutées à une HTA chronique. **Ce pourcentage décrit l'échantillon : ce n'est pas la prévalence de la prééclampsie dans la population générale de Kara** (échantillon hospitalier simulé).

Comment l'écrire dans le mémoire

Parmi les 400 femmes enceintes incluses, 48 présentaient une prééclampsie, soit une proportion de 12,0 % dans l'échantillon (40 prééclampsies et 8 prééclampsies surajoutées à une HTA chronique).

Question 5 – Existe-t-il une association entre l'âge maternel et la prééclampsie ?

Variables	Tranche d'âge (`tranche_age`) × prééclampsie
Méthode	Tableau croisé (pourcentages en ligne) puis test du Chi-deux ou exact de Fisher
Hypothèses	H0 : la fréquence de la prééclampsie est la même dans toutes les tranches d'âge (pas d'association). H1 : elle diffère dans au moins une tranche d'âge.
Conditions	Condition : au moins un effectif attendu est < 5 (minimum observé : 2,5) → le Chi-deux n'est pas fiable, on utilise le test exact de Fisher.

Code R (extrait du script)

```
# QUESTION 5 : Existe-t-il une association entre l'âge maternel et la prééclampsie ?
tab_q5 <- table(donnees$tranche_age, donnees$preeclampsie)
tab_q5
round(100 * prop.table(tab_q5, 1), 1)                    # % de prééclampsie dans chaque tranche d'âge

attendus_q5 <- outer(rowSums(tab_q5), colSums(tab_q5)) / sum(tab_q5)
round(attendus_q5, 1)                                    # effectifs attendus sous H0
if (min(attendus_q5) >= 5) {
  methode_q5 <- "Chi-deux"
  test_q5 <- chisq.test(tab_q5, correct = FALSE)
} else {
  methode_q5 <- "Fisher"
  test_q5 <- fisher.test(tab_q5)
}
test_q5
p_q5 <- test_q5$p.value
cat("Test :", methode_q5, "; p-value =", virgule(p_q5, 3), "\n")
if (p_q5 < 0.05) {
  cat("Conclusion : association statistiquement significative (p < 0,05).\n")
} else {
  cat("Conclusion : association non démontrée ici (p >= 0,05). Cela ne prouve pas l'absence d'association.\n")
}
```

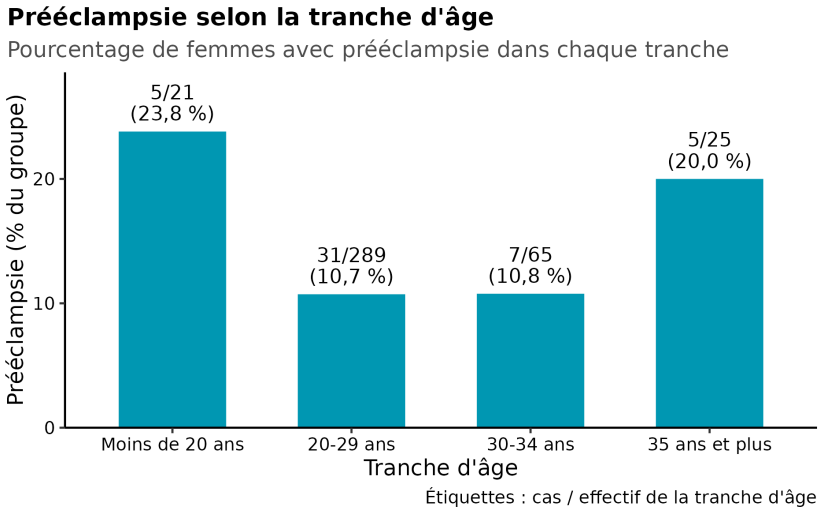
Que fait ce code ?

- `prop.table(tab, 1)` : pourcentages par ligne (dans chaque tranche d'âge).
- `outer()` calcule les effectifs attendus sous H0.
- `if … else` applique la règle : attendus tous ≥ 5 → Chi-deux, sinon Fisher.
- `$p.value` extrait la p-value du résultat du test.

Résultat

Modalité	Effectif total	Cas de prééclampsie (n)	% de prééclampsie dans le groupe
Moins de 20 ans	21	5	23,8
20-29 ans	289	31	10,7
30-34 ans	65	7	10,8
35 ans et plus	25	5	20,0

Test exact de Fisher : p = 0,165



Interprétation

Le pourcentage de prééclampsie va de 10,7 % (20-29 ans) à 23,8 % (Moins de 20 ans). Cette différence n'est pas statistiquement significative (p = 0,165). Dans cet échantillon, on ne peut donc pas conclure à une association entre ces deux variables. **Attention : p ≥ 0,05 ne prouve pas l'absence d'association** ; la plus petite tranche ne compte que 21 femmes, ce qui limite la puissance du test.

Comment l'écrire dans le mémoire

Le pourcentage de prééclampsie était de 23,8 % (5/21) pour la tranche « Moins de 20 ans »; 10,7 % (31/289) pour la tranche « 20-29 ans »; 10,8 % (7/65) pour la tranche « 30-34 ans »; 20,0 % (5/25) pour la tranche « 35 ans et plus » (test exact de Fisher, p = 0,165).

Note pour le formateur : Dans la simulation, un surrisque modéré a été programmé pour les moins de 20 ans et les 35 ans et plus, mais les effectifs de ces tranches sont faibles : c'est un bon exemple pour expliquer qu'un résultat non significatif ne prouve pas l'absence d'association.

Question 6 – Les femmes ayant des antécédents de prééclampsie présentent-elles plus fréquemment une prééclampsie pendant la grossesse étudiée ?

Variables	Antécédent personnel de prééclampsie (`atcd_preeclampsie`) × prééclampsie
Méthode	Restriction aux femmes déjà accouchées (parité ≥ 1) et dont l'antécédent est renseigné (n = 286) ; tableau de contingence ; test adapté
Hypothèses	H0 : la fréquence de la prééclampsie est la même chez les femmes avec et sans antécédent de prééclampsie. H1 : elle diffère.
Conditions	Condition : au moins un effectif attendu est < 5 (minimum observé : 2,6) → le Chi-deux n'est pas fiable, on utilise le test exact de Fisher.

Code R (extrait du script)

```
# QUESTION 6 : Les femmes ayant un antécédent de prééclampsie présentent-elles plus
#              souvent une prééclampsie ? (seulement les femmes déjà accouchées)
multipares <- donnees[donnees$parite >= 1 & donnees$atcd_preeclampsie %in% c("Oui", "Non"), ]
multipares <- droplevels(multipares)
nrow(multipares)                                        # effectif analysé

tab_q6 <- table(multipares$atcd_preeclampsie, multipares$preeclampsie)
tab_q6
round(100 * prop.table(tab_q6, 1), 1)

attendus_q6 <- outer(rowSums(tab_q6), colSums(tab_q6)) / sum(tab_q6)
round(attendus_q6, 1)
if (min(attendus_q6) >= 5) {
  methode_q6 <- "Chi-deux"
  test_q6 <- chisq.test(tab_q6, correct = FALSE)
} else {
  methode_q6 <- "Fisher"
  test_q6 <- fisher.test(tab_q6)
}
test_q6
p_q6 <- test_q6$p.value
cat("Test :", methode_q6, "; p-value =", virgule(p_q6, 3), "\n")
if (p_q6 < 0.05) {
  cat("Conclusion : association statistiquement significative (p < 0,05).\n")
} else {
  cat("Conclusion : association non démontrée ici (p >= 0,05). Cela ne prouve pas l'absence d'association.\n")
}
```

Que fait ce code ?

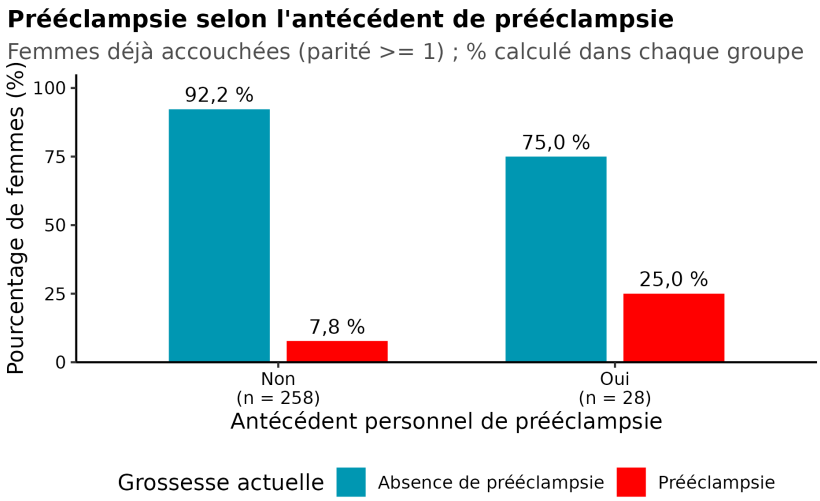
- On **garde seulement** les femmes avec parité ≥ 1 et antécédent « Oui » ou « Non » : `donnees[condition, ]`.
- `droplevels()` retire la modalité « Non applicable » devenue vide.
- Ensuite, même modèle que la Question 5.

Résultat

Précaution : 114 femmes sont exclues de cette analyse : 108 nullipares (aucune grossesse antérieure, donc antécédent « non applicable ») et 6 femmes déjà accouchées dont l'antécédent n'est pas renseigné.

Modalité	Effectif total	Cas de prééclampsie (n)	% de prééclampsie dans le groupe
Non	258	20	7,8
Oui	28	7	25,0

Test exact de Fisher : p = 0,009



Interprétation

Le pourcentage de prééclampsie va de 7,8 % (Non) à 25,0 % (Oui). Cette différence est statistiquement significative (p = 0,009) : dans cet échantillon, l'antécédent de prééclampsie est **associé(e)** à la prééclampsie. Ce résultat décrit une association ; il ne démontre pas une relation de cause à effet (étude transversale, analyse non ajustée). Cette analyse ne porte que sur 286 femmes (celles déjà accouchées et à antécédent renseigné).

Comment l'écrire dans le mémoire

Parmi les 286 femmes déjà accouchées et dont l'antécédent était renseigné, la prééclampsie était observée chez 25,0 % (7/28) des femmes ayant un antécédent de prééclampsie contre 7,8 % (20/258) de celles sans antécédent (test exact de Fisher, p = 0,009).

Question 7 – Existe-t-il une association entre l'hypertension artérielle chronique et la prééclampsie ?

Variables	Antécédent d'HTA chronique (`atcd_hta_chronique`) × prééclampsie (toutes formes)
Méthode	Tableau croisé puis test adapté ; lecture du diagnostic en 5 catégories pour distinguer prééclampsie et prééclampsie surajoutée
Hypothèses	H0 : la fréquence de la prééclampsie est la même chez les femmes avec et sans HTA chronique. H1 : elle diffère.
Conditions	Condition : au moins un effectif attendu est < 5 (minimum observé : 2,8) → le Chi-deux n'est pas fiable, on utilise le test exact de Fisher.

Code R (extrait du script)

```
# QUESTION 7 : Existe-t-il une association entre l'HTA chronique et la prééclampsie ?
# Rappel : la prééclampsie "toutes formes" comprend la prééclampsie surajoutée,
# qui ne peut survenir que chez une femme ayant une HTA chronique.
tab_q7_types <- table(donnees$type_diagnostic, donnees$atcd_hta_chronique)
tab_q7_types

tab_q7 <- table(donnees$atcd_hta_chronique, donnees$preeclampsie)
tab_q7
round(100 * prop.table(tab_q7, 1), 1)

attendus_q7 <- outer(rowSums(tab_q7), colSums(tab_q7)) / sum(tab_q7)
round(attendus_q7, 1)
if (min(attendus_q7) >= 5) {
  methode_q7 <- "Chi-deux"
  test_q7 <- chisq.test(tab_q7, correct = FALSE)
} else {
  methode_q7 <- "Fisher"
  test_q7 <- fisher.test(tab_q7)
}
test_q7
p_q7 <- test_q7$p.value
cat("Test :", methode_q7, "; p-value =", virgule(p_q7, 3), "\n")
if (p_q7 < 0.05) {
  cat("Conclusion : association statistiquement significative (p < 0,05).\n")
} else {
  cat("Conclusion : association non démontrée ici (p >= 0,05). Cela ne prouve pas l'absence d'association.\n")
}
```

Que fait ce code ?

- Un premier tableau montre les 5 diagnostics selon l'HTA chronique ; le second est le tableau 2 × 2 testé.
- Même modèle que la Question 5.

Résultat

Diagnostic en 5 catégories selon l'HTA chronique (on voit que la prééclampsie « surajoutée » n'existe que chez les femmes hypertendues chroniques) :

Diagnostic final	Sans HTA chronique	Avec HTA chronique
Normotendue	327	0
HTA gestationnelle	10	0
HTA chronique seule	0	15
Prééclampsie	40	0
Prééclampsie surajoutée	0	8

Modalité	Effectif total	Cas de prééclampsie (n)	% de prééclampsie dans le groupe
Non	377	40	10,6
Oui	23	8	34,8

Test exact de Fisher : p = 0,003

Interprétation

Le pourcentage de prééclampsie va de 10,6 % (Non) à 34,8 % (Oui). Cette différence est statistiquement significative (p = 0,003) : dans cet échantillon, l'HTA chronique est **associé(e)** à la prééclampsie. Ce résultat décrit une association ; il ne démontre pas une relation de cause à effet (étude transversale, analyse non ajustée). **Nuance :** la prééclampsie « toutes formes » inclut la prééclampsie surajoutée, qui par définition ne peut survenir que chez les femmes avec HTA chronique. Chez les femmes sans HTA chronique, seule la prééclampsie « pure » est possible (40/377, 10,6 %) ; chez celles avec HTA chronique, tous les cas sont des prééclampsies surajoutées (8/23, 34,8 %).

Comment l'écrire dans le mémoire

La prééclampsie (toutes formes) était observée chez 34,8 % (8/23) des femmes ayant une HTA chronique (prééclampsies surajoutées) contre 10,6 % (40/377) des femmes sans HTA chronique (test exact de Fisher, p = 0,003).

Note pour le formateur : Le nombre de femmes avec HTA chronique est faible (23) : le test exact de Fisher est le bon choix.

Question 8 – La fréquence de la prééclampsie varie-t-elle selon la parité ?

Variables	Parité en 3 groupes (`groupe_parite`) × prééclampsie
Méthode	Tableau croisé (pourcentages en ligne) puis test du Chi-deux ou de Fisher
Hypothèses	H0 : la fréquence de la prééclampsie est la même dans les trois groupes de parité. H1 : elle diffère dans au moins un groupe.
Conditions	Condition : tous les effectifs attendus sont ≥ 5 (minimum observé : 10,7) → test du Chi-deux.

Code R (extrait du script)

```
# QUESTION 8 : La fréquence de la prééclampsie varie-t-elle selon la parité ?
tab_q8 <- table(donnees$groupe_parite, donnees$preeclampsie)
tab_q8
round(100 * prop.table(tab_q8, 1), 1)

attendus_q8 <- outer(rowSums(tab_q8), colSums(tab_q8)) / sum(tab_q8)
round(attendus_q8, 1)
if (min(attendus_q8) >= 5) {
  methode_q8 <- "Chi-deux"
  test_q8 <- chisq.test(tab_q8, correct = FALSE)
} else {
  methode_q8 <- "Fisher"
  test_q8 <- fisher.test(tab_q8)
}
test_q8
p_q8 <- test_q8$p.value
cat("Test :", methode_q8, "; p-value =", virgule(p_q8, 3), "\n")
if (p_q8 < 0.05) {
  cat("Conclusion : association statistiquement significative (p < 0,05).\n")
} else {
  cat("Conclusion : association non démontrée ici (p >= 0,05). Cela ne prouve pas l'absence d'association.\n")
}
```

Que fait ce code ?

- La parité a été regroupée en 3 classes avec `cut()` (Section 2).
- `correct = FALSE` : Chi-deux de Pearson, celui d'Epi Info et de Stata.

Résultat

Modalité	Effectif total	Cas de prééclampsie (n)	% de prééclampsie dans le groupe
Nullipare (0)	108	21	19,4
1-2 accouchements	203	13	6,4
3 accouchements et plus	89	14	15,7

Test du Chi-deux de Pearson : p = 0,002

Interprétation

Le pourcentage de prééclampsie va de 6,4 % (1-2 accouchements) à 19,4 % (Nullipare (0)). Cette différence est statistiquement significative (p = 0,002) : dans cet échantillon, la parité est **associé(e)** à la prééclampsie. Ce résultat décrit une association ; il ne démontre pas une relation de cause à effet (étude transversale, analyse non ajustée). Le pourcentage le plus élevé s'observe pour « Nullipare (0) ». Attention : le profil n'est pas linéaire et l'âge et la parité sont liés ; seule une analyse multivariée permettrait de séparer leurs effets (hors du cadre de cet atelier).

Comment l'écrire dans le mémoire

La fréquence de la prééclampsie variait selon la parité : 19,4 % (21/108) pour « nullipare (0) »; 6,4 % (13/203) pour « 1-2 accouchements »; 15,7 % (14/89) pour « 3 accouchements et plus » (test du Chi-deux, p = 0,002).

Note pour le formateur : Seul exemple de l'atelier où le test du Chi-deux est applicable (tous les effectifs attendus ≥ 5) : c'est pour cela que les parités ont été regroupées en 3 classes. Les classes de parité varient

selon les auteurs : toujours justifier et définir son découpage dans le mémoire.

Question 9 – Existe-t-il une association entre la grossesse multiple et la prééclampsie ?

Variables	Type de grossesse (`type_grossesse`) × prééclampsie
Méthode	Tableau de contingence puis test adapté
Hypothèses	H0 : la fréquence de la prééclampsie est la même pour les grossesses uniques et multiples. H1 : elle diffère.
Conditions	Condition : au moins un effectif attendu est < 5 (minimum observé : 1,7) → le Chi-deux n'est pas fiable, on utilise le test exact de Fisher.

Code R (extrait du script)

```
# QUESTION 9 : Existe-t-il une association entre la grossesse multiple et la prééclampsie ?
tab_q9 <- table(donnees$type_grossesse, donnees$preeclampsie)
tab_q9
round(100 * prop.table(tab_q9, 1), 1)

attendus_q9 <- outer(rowSums(tab_q9), colSums(tab_q9)) / sum(tab_q9)
round(attendus_q9, 1)
if (min(attendus_q9) >= 5) {
  methode_q9 <- "Chi-deux"
  test_q9 <- chisq.test(tab_q9, correct = FALSE)
} else {
  methode_q9 <- "Fisher"
  test_q9 <- fisher.test(tab_q9)
}
test_q9
p_q9 <- test_q9$p.value
cat("Test :", methode_q9, "; p-value =", virgule(p_q9, 3), "\n")
if (p_q9 < 0.05) {
  cat("Conclusion : association statistiquement significative (p < 0,05).\n")
} else {
  cat("Conclusion : association non démontrée ici (p >= 0,05). Cela ne prouve pas l'absence d'association.\n")
}
```

Que fait ce code ?

- Même modèle que la Question 5 : seuls les noms de variables changent.
- Peu de grossesses multiples : Fisher.

Résultat

Modalité	Effectif total	Cas de prééclampsie (n)	% de prééclampsie dans le groupe
Unique	386	46	11,9
Multiple	14	2	14,3

Test exact de Fisher : p = 0,679

Interprétation

Le pourcentage de prééclampsie va de 11,9 % (Unique) à 14,3 % (Multiple). Cette différence n'est pas statistiquement significative (p = 0,679). Dans cet échantillon, on ne peut donc pas conclure à une association entre ces deux variables. **Attention : p ≥ 0,05 ne prouve pas l'absence d'association** ; seules 14 grossesses sont multiples (2 cas de prééclampsie) : l'effectif est trop faible pour détecter une différence.

Comment l'écrire dans le mémoire

La prééclampsie était observée chez 14,3 % (2/14) des grossesses multiples contre 11,9 % (46/386) des grossesses uniques (test exact de Fisher, p = 0,679).

Note pour le formateur : La grossesse multiple est un facteur de risque reconnu dans la littérature, et un surrisque a été programmé dans la simulation ; avec seulement 14 grossesses multiples, le test ne peut pas le détecter. Excellent exemple de manque de puissance.

Question 10 – L'âge moyen diffère-t-il entre les femmes présentant une prééclampsie et celles n'en présentant pas ?

Variables	Âge maternel (`age_ans`) × statut de prééclampsie
Méthode	Comparaison de deux moyennes : test t de Student (Welch) si au moins 30 femmes par groupe, sinon test de Wilcoxon
Hypothèses	H0 : l'âge moyen est le même chez les femmes avec et sans prééclampsie. H1 : les âges moyens sont différents.
Conditions	Condition : au moins 30 femmes par groupe (effectif minimal observé : 48) → le test t de Student (version de Welch, qui ne suppose pas des variances égales) est applicable.

Code R (extrait du script)

```
# QUESTION 10 : L'âge moyen diffère-t-il entre les femmes avec et sans prééclampsie ?
# H0 : les moyennes d'âge sont égales.  H1 : les moyennes d'âge sont différentes.
effectifs_groupes <- table(donnees$preeclampsie)
effectifs_groupes
tapply(donnees$age_ans, donnees$preeclampsie, mean, na.rm = TRUE)
tapply(donnees$age_ans, donnees$preeclampsie, sd, na.rm = TRUE)
tapply(donnees$age_ans, donnees$preeclampsie, median, na.rm = TRUE)

# Condition : au moins 30 femmes dans chaque groupe -> test t ; sinon test de Wilcoxon
if (min(effectifs_groupes) >= 30) {
  methode_q10 <- "Test t de Student (Welch)"
  test_q10 <- t.test(age_ans ~ preeclampsie, data = donnees)
} else {
  methode_q10 <- "Wilcoxon"
  test_q10 <- wilcox.test(age_ans ~ preeclampsie, data = donnees, exact = FALSE)
}
test_q10
p_q10 <- test_q10$p.value
cat("Test :", methode_q10, "; p-value =", virgule(p_q10, 3), "\n")
if (p_q10 < 0.05) {
  cat("Conclusion : différence statistiquement significative (p < 0,05).\n")
} else {
  cat("Conclusion : différence non démontrée ici (p >= 0,05). Cela ne prouve pas l'absence de différence.\n")
}

tableau_q10 <- data.frame(
  Groupe     = c("Absence de prééclampsie", "Prééclampsie"),
  Effectif   = as.vector(effectifs_groupes),
  Moyenne    = round(as.vector(tapply(donnees$age_ans, donnees$preeclampsie, mean, na.rm = TRUE)), 1),
  Ecart_type = round(as.vector(tapply(donnees$age_ans, donnees$preeclampsie, sd, na.rm = TRUE)), 1),
  Mediane    = as.vector(tapply(donnees$age_ans, donnees$preeclampsie, median, na.rm = TRUE)))
tableau_q10
```

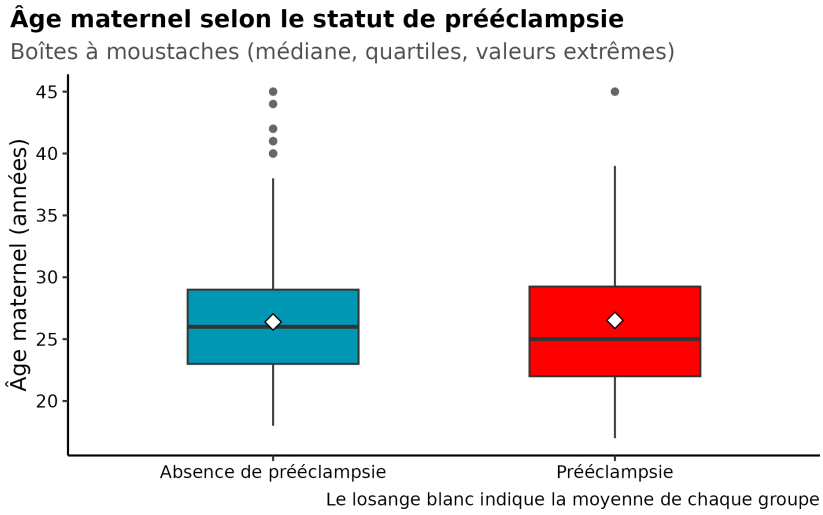
Que fait ce code ?

- `tapply(x, groupe, mean)` calcule la moyenne de x dans chaque groupe.
- `age_ans ~ preeclampsie` se lit « l'âge en fonction du statut de prééclampsie ».
- Si moins de 30 femmes par groupe, le script bascule sur `wilcox.test()`.

Résultat

Groupe	Effectif	Moyenne d'âge (ans)	Écart-type	Médiane
Absence de prééclampsie	352	26,4	4,8	26
Prééclampsie	48	26,5	6,1	25

Test t de Student (Welch) : p = 0,887



Interprétation

L'âge moyen est de 26,5 ans avec prééclampsie et de 26,4 ans sans (différence de 0,1 an). La différence n'est pas statistiquement significative (p = 0,887) : on ne met pas en évidence de différence d'âge moyen. Ceci ne prouve pas l'absence de lien entre l'âge et la prééclampsie. Le boxplot montre une dispersion plus grande dans le groupe prééclampsie (écart-type 6,1 contre 4,8).

Comment l'écrire dans le mémoire

L'âge moyen était de 26,5 ± 6,1 ans chez les femmes avec prééclampsie et de 26,4 ± 4,8 ans chez celles sans prééclampsie (test t de Student, p = 0,887).

Note pour le formateur : Piège pédagogique : les moyennes d'âge sont presque égales alors que le Q5 montre plus de prééclampsie aux âges extrêmes (profil en U). Un test de comparaison de moyennes ne détecte pas une relation non linéaire : d'où l'intérêt de regarder aussi les tranches d'âge.

6. Partie D – Difficultés fréquentes

Problème	Message ou symptôme	Cause probable	Solution simple
Package non installé	`Error in library(ggplot2): there is no package called 'ggplot2'`	ggplot2 absent ou installation impossible (pas d'Internet).	Avec Internet : `install.packages("ggplot2")`. Le script le fait seul. Sans Internet : installer le package la veille ; sinon montrer les PNG déjà produits.
Fichier CSV introuvable	`Fichier de données introuvable` ou `cannot open file`	Le projet n'est pas ouvert ; l'archive n'est pas décompressée ; dossier renommé.	Décompresser le ZIP ; double-cliquer `Atelier_TFE.Rproj` ; ne pas renommer les dossiers 01_DONNEES, 02_SCRIPTS_R…
Mauvais nom de variable	`object 'Age' not found` ou résultat `NULL`	R distingue majuscules, minuscules et accents : `age_ans` ≠ `Age_ans`.	Vérifier avec `names(donnees)` et recopier exactement.
Erreur de syntaxe	`unexpected ')'` ou la console affiche « + » sans fin	Parenthèse, guillemet ou virgule oublié(e).	Appuyer sur Échap, relire la ligne : chaque « (» ferme un «) », chaque guillemet est fermé.
Nombre importé comme texte	`str()` montre `chr` pour l'IMC ; moyenne = NA et avertissement	Mauvais séparateur : `read.csv()` au lieu de `read.csv2()` pour un CSV français (virgule décimale).	Utiliser `read.csv2()`. Sinon convertir : `as.numeric(gsub(",", ".", x))`.
Valeurs manquantes	`mean(donnees$imc)` renvoie `NA`	Une seule valeur manquante rend le résultat NA.	Ajouter `na.rm = TRUE` et signaler l'effectif valide dans le tableau.
Accents illisibles	« PrÃ©Ã©clampsie » dans le script ou les graphiques	Fichier ouvert avec le mauvais encodage.	File → Reopen with Encoding → UTF-8. Les CSV exportés s'ouvrent correctement dans Excel (encodage Windows-1252).
Mauvaise interprétation d'une p-value	« p = 0,165 donc l'âge n'a aucun effet »	Confusion entre absence de preuve et preuve d'absence.	Dire : « association non démontrée dans cet échantillon ». Regarder les effectifs et la taille de l'échantillon. Ne jamais conclure à une cause.

7. Annexes

Annexe A – Choisir le test adapté

Situation	Test	Fonction R
2 variables qualitatives, effectifs attendus tous ≥ 5	Chi-deux de Pearson	`chisq.test(tab, correct = FALSE)`
2 variables qualitatives, au moins un effectif attendu < 5	Test exact de Fisher	`fisher.test(tab)`
1 variable quantitative, 2 groupes, ≥ 30 par groupe	Test t de Student (Welch)	`t.test(y ~ groupe, data = donnees)`
1 variable quantitative, 2 groupes, effectifs faibles ou distribution très asymétrique	Test de Wilcoxon	`wilcox.test(y ~ groupe, data = donnees, exact = FALSE)`

Annexe B – Adapter le script à son propre mémoire

- Placer son fichier CSV dans `01_DONNEES` (séparateur « ; »). Si le séparateur est « , » et le point décimal « . », utiliser `read.csv()`.
- Dans la Section 1, remplacer `donnees_TFE_preeclampsie_Kara.csv` par le nom de son fichier.
- Remplacer les noms de variables (`age_ans`, `preeclampsie`…) par les siens (vérifier avec `names(donnees)`).

- Adapter les modalités des `factor(…, levels = …)` et les bornes des `cut(…)` à ses propres classes.
- Garder le modèle de la Question 5 pour chaque nouveau facteur : changer uniquement le nom de la variable explicative.
- La variable de résultat doit comporter les modalités « Non » et « Oui » (la table utilise `"Oui"` pour les cas).
- Relancer tout le script (Ctrl + Maj + Entrée) : tableaux et graphiques sont régénérés.

Annexe C – Rapport de vérification technique

Ce qui a réellement été exécuté lors de la conception :

Vérification	Résultat
Environnement	R 4.3.3 sous Linux (Rscript), ggplot2 3.4.4
01_generation_donnees.R exécuté 2 fois (code retour 0)	Fichier CSV identique (empreinte MD5 c4bafd43437c520fb0984e4982868c13) ; 400 lignes, 22 colonnes ; contrôles stopifnot() réussis
02_analyse_TFE.R exécuté depuis la racine du projet	code retour 0 ; 0 erreur ; 0 avertissement ; 11 tableaux CSV et 5 graphiques PNG créés
02_analyse_TFE.R exécuté depuis 02_SCRIPTS_R	code retour 0 ; résultats CSV strictement identiques à ceux obtenus depuis la racine
Création automatique des dossiers de résultats (dossier 05_RESULTATS supprimé avant exécution)	code retour 0 ; 11 tableaux et 5 graphiques recréés
Graphiques PNG	5 fichiers, résolution 300 dpi, 16 x 10 cm ; contrôle visuel réalisé sur les 5 figures

Non vérifié dans l'environnement de conception : exécution sous Windows avec RStudio ; installation de ggplot2 depuis CRAN sur un poste Windows ; ouverture des CSV dans Excel. Un essai complet sur l'ordinateur de la séance la veille est indispensable.